

Spider monkey optimization for traveling salesman problem

Antoni Zajko, Dawid Płudowski, Franciszek Szczepaniak,
Kamil Kisiel, Maciej Szpetmański

Warsaw University of Technology

2023

Reprezentacja rozwiązania

- ▶ Rozwiązanie jest reprezentowane jako permutacja wierzchołków grafu.
- ▶ Permutacja - swap sequence (SS) - może być reprezentowana jako lista transpozycji - swap operation (SO)
- ▶ $SS = (SO_1, SO_2, \dots, SO_k)$

Operatory

$$\begin{aligned} SS_1 + SS_2 &= (SO_1^1, SO_2^1, \dots, SO_{k_1}^1) + (SO_1^2, SO_2^2, \dots, SO_{k_2}^2) \\ &= (SO_1^1, SO_2^1, \dots, SO_{k_1}^1, SO_1^2, SO_2^2, \dots, SO_{k_2}^2) \end{aligned}$$

Operator

$$SS_1 - SS_2 = (SO_1, SO_2, \dots SO_k)$$

Gdzie:

$$SS_2 + (SO_1, SO_2, \dots SO_k) = SS_1$$

Operatory

$$\begin{aligned}U(0,1)SS_1 &= U(0,1)(SO_1, SO_2, \dots SO_k) \\ &= (SO_{i_1}, SO_{i_2}, \dots SO_{i_s})\end{aligned}$$

Gdzie:

$$s \sim U([1, k])$$

i_1, i_2, \dots, i_s – losowe indeksy z $[k]$, $i_1 < i_2 < \dots < i_s$

Algorytm SM wysokopoziomowo

Inicjalizacja:

- Zainicjalizuj populację małąp

- Znajdź globalnego lidera populacji

- Utwórz grupę małąp g_1 składającą się z całej populacji.

- Ustaw globalnego lidera grupy na lokalnego lidera.

Algorytm:

- Dopóki kryterium stopu nie zostanie spełnione:

 - Faza lokalnego lidera

 - Faza globalnego lidera

 - Faza uczenia lokalnego lidera

 - Faza uczenia globalnego lidera

 - Faza decyzji lokalnego lidera

 - Faza decyzji globalnego lidera

Algorytm SM wysokopoziomowo

Hiperparametry algorytmu:

- ▶ G_{max} - dozwolona maksymalna liczba grup
- ▶ p - perturbation rate
- ▶ LC_{max} - local leader limit
- ▶ GC_{max} - global lider limit
- ▶ N - rozmiar populacji

Algorytm SM wysokopoziomowo

Oznaczenia:

- ▶ f - funkcja kosztu, która mapuje małąpę reprezentującą cykl Hamiltona na jego koszt
- ▶ LL_g - lokalny lider grupy g
- ▶ LC_g - licznik lokalnego lidera grupy g
- ▶ GL - globalny lider całej populacji
- ▶ GC - licznik globalnego lidera
- ▶ G_c - ilość grup

Faza lokalnego lidera

Dla każdej grupy małąp g :

Dla każdej małąpy m w grupie g :

Jeżeli $U(0, 1) \geq p$:

m_r = losowa małąpa z g

$$m_{new} = m + U(0, 1)(LL_g - m) + U(0, 1)(m_r - m)$$

Jeżeli $f(m_{new}) \leq f(m)$ to:

$$m = m_{new}$$

Faza globalnego lidera

Dla każdej grupy małąp g :

Dla każdej małąpy m w grupie g :

$$p_m = 0.9 * \frac{f(GL)}{f(m)} + 0.1$$

Jeżeli $U(0, 1) \leq p_m$ to:

m_r = losowa małąpa z populacji

$$m_{new} = m + U(0, 1)(GL - m) + U(0, 1)(m_r - m)$$

Jeżeli $f(m_{new}) \leq f(m)$ to:

$$m = m_{new}$$

Faza uczenia lokalnego lidera

Dla każdej grupy małąp g :

$LL_{g,new}$ = małąp w grupie posiadająca najmniejszą wartość f

Jeżeli $f(LL_{g,new}) < f(LL_g)$ to:

$$LL_g = LL_{g,new}$$

$$LC_g = 0$$

W przeciwnym przypadku:

$$LC_g = LC_g + 1$$

Faza uczenia globalnego lidera

GL_{new} = Lokalny lider o najmniejszym f

Jeżeli $f(GL_{new}) < f(GL)$:

$$GL = GL_{new}$$

$$GC = 0$$

W przeciwnym wypadku:

$$GC = GC + 1$$

Faza decyzji lokalnego lidera

Dla każdej grupy małąp g :

Jeżeli $LC_g > LC_{max}$:

$$LC_g = 0$$

Dla każdej małąpy m w g :

Jeżeli $U(0, 1) \geq p$:

m = losowe rozwiązanie

W przeciwnym wypadku:

$$m = m + U(0, 1)(GL - m) + U(0, 1)(LL_g - m)$$

Faza decyzji globalnego lidera

Jeżeli $GC > GC_{max}$:

$$GC = 0$$

Jeżeli $G_c < G_{max}$:

Podziel losową grupę małą na 2 grupy

$$G_c = G_c + 1$$

W przeciwnym wypadku:

Złącz wszystkie grupy w jedną grupę

$$G_c = 1$$

Zalety

- ▶ Jeden z najlepszych algorytmów rojowych do tego problemu
- ▶ Możliwe duże zrównoleglenie przetwarzania grup
- ▶ Szybko osiąga relatywnie dobre rozwiązania
- ▶ Stabilny

Wady

- ▶ Wypada kiepsko przy innych algorytmach optymalizacyjnych
- ▶ Wymaga relatywnie dużo osobników do dobrej eksploracji przestrzeni
- ▶ Wolna zbieżność do optimum globalnego
- ▶ Wpada w minima lokalne

Bibliografia

- [1] M.A.H. Akhand and Safial Islam Ayon and S.A. Shahriyar and N. Siddique and H. Adeli (2020) *Discrete Spider Monkey Optimization for Travelling Salesman Problem*, Applied Soft Computing.